

전체 경로 도착확률 및 AI 적용 설계

RailOdds 전체 경로 도착확률 및 AI 적용 설계

1. 목표

RailOdds는 열차 한 대의 도착시간만 보여주는 것이 아니라, 사용자가 집에서 출발해 환승을 거쳐 목적역에 도착할 때까지의 전체 과정을 계산한다.

사용자에게 제공할 핵심 정보는 다음과 같다.

- 지금 출발하면 목적역에 몇 시쯤 도착하는가?
- 특정 시각까지 도착할 확률은 얼마인가?
- 계획한 첫 열차와 환승열차를 탈 확률은 얼마인가?
- 환승을 놓쳐도 다음 열차를 타고 제시간에 도착할 수 있는가?
- 목표 도착확률 90%를 만족하려면 언제 집에서 나가야 하는가?

현재 기획서의 역별 ETA 신뢰도 계산만으로는 전체 경로를 계산할 수 없다. 이를 위해 **AI 지연 예측 모델**과 **Monte Carlo 전체 경로 시뮬레이션**이 추가로 필요하다.

2. 핵심 구조

서울교통공사 API

- 현재 열차 및 경로 정보 수집
- LightGBM이 열차 지연 확률분포 예측
- Monte Carlo가 지연시간을 표본추출
- 집부터 목적역까지 가상 이동
- 정시 도착확률·환승 성공확률 계산

각 기술의 역할은 다음과 같다.

구성요소	역할
경로 탐색 API	출발역부터 목적역까지의 열차·환승 경로 생성
LightGBM	현재 조건에서 열차가 얼마나 지연될지 확률분포 예측
Monte Carlo	예측된 분포에서 값을 뽑아 전체 여행을 반복 실행
확률 집계	목적지 도착시각과 정시 도착확률 계산

LightGBM이 최종 도착확률을 직접 계산하는 것이 아니다.

LightGBM은 시뮬레이션에 필요한 열차별 지연 확률분포를 만들고, Monte Carlo가 그 결과를 사용해 실제 여행 과정을 수천 번 실행한다.

3. 전체 경로 계산 범위

전체 여행은 다음 단계로 구성된다.

집
→ 출발역 승강장
→ 첫 번째 열차
→ 환승역
→ 환승 통로 이동
→ 환승열차 또는 다음 열차
→ 목적역 도착

MVP에서는 목적지 도착 기준을 목적역 하차 승강장 도착으로 정의한다.

목적역 출구까지 계산하려면 출구 위치와 역사 내부 이동시간을 추가해야 한다.

4. LightGBM 지연 예측 모델

4.1 학습 데이터

LightGBM에는 다음 정보를 입력한다.

- 호선·역·방향
- 평일·주말
- 시간대
- 일반·급행 여부
- TOPIS ETA의 리드타임
- 현재 열차 지연
- 이전 역에서의 지연
- 앞 열차와의 배차간격
- 평상시 혼잡도
- 지연·사고 알림 여부

학습 정답은 다음과 같다.

예측 오차
= 실제 도착시각 - TOPIS 도착예정시각

예를 들어 TOPIS가 08:10:00 도착을 예측했지만 실제로 08:11:20에 도착했다면 정답은 +80초다.

4.2 예측 결과

일반적인 회귀 모델은 다음과 같이 평균값 하나를 예측한다.

예상 지연: 45초

LightGBM Quantile Regression은 여러 분위수의 지연시간을 예측한다.

분위수	예측 지연
P10	-20초
P30	0초
P50	+30초
P70	+90초
P90	+150초

해석은 다음과 같다.

- P10: 실제 지연의 약 10%가 -20초 이하
- P50: 절반은 30초 이하, 절반은 30초 이상
- P90: 약 90%는 150초 이하
- 나머지 약 10%는 150초보다 더 늦을 수 있음

P90이 "150초 지연될 확률이 90%"라는 뜻은 아니다.

실제 구현에서는 다음과 같이 여러 분위수 모델을 학습한다.

P05, P10, P20, P30, P40
P50
P60, P70, P80, P90, P95

5. LightGBM 결과를 Monte Carlo가 사용하는 방법

5.1 확률분포에서 지연시간 뽑기

LightGBM은 지연 분포의 여러 지점을 예측한다.

Monte Carlo는 0부터 1 사이의 난수를 생성하고, 해당 위치에 해당하는 지연시간을 선택한다.

이번 시뮬레이션 난수 $U = 0.72$

LightGBM 결과에서 P70은 90초, P90은 150초다.

0.72는 P70과 P90 사이이므로 두 값 사이를 보간한다.

P70: +90초
P90: +150초
U: 0.72

이번 시뮬레이션 지연: 약 +96초

TOPIS 도착예정시각이 08:10:00이라면:

TOPIS 도착예정시각: 08:10:00
표본추출된 지연: +1분 36초
가상 실제 도착시각: 08:11:36

수식으로 표현하면 다음과 같다.

$U = 0 \sim 1$ 사이 난수
지연시간 = LightGBM 분위수 분포에서 $Q(U)$ 선택
가상 도착시각 = TOPIS 도착예정시각 + 지연시간

5.2 반복할 때마다 다른 값 선택

동일한 LightGBM 결과를 사용하더라도 난수가 달라지면 시뮬레이션 결과도 달라진다.

시뮬레이션	난수	선택된 지연	가상 도착
1	0.15	-12초	08:09:48
2	0.42	+18초	08:10:18
3	0.72	+96초	08:11:36
4	0.88	+144초	08:12:24
5	0.55	+45초	08:10:45

이 과정을 수천 번 반복하면 LightGBM의 확률 예측이 실제 도착시간 분포로 변환된다.

6. 한 번의 전체 경로 시뮬레이션

사용자가 08:00에 집에서 출발한다고 가정한다.

6.1 집에서 승강장까지 이동

집 출발시각: 08:00:00
 집→승강장 이동시간: 8분 20초
 승강장 도착시각: 08:08:20

MVP에서는 사용자가 평소 집에서 승강장까지 걸리는 시간을 입력한다.

추후 사용자 이동기록이 쌓이면 이 시간도 확률분포로 만들 수 있다.

6.2 첫 번째 열차 탑승

TOPIS 예정 도착: 08:10:00
 LightGBM 표본 지연: +96초
 가상 실제 도착: 08:11:36
 가상 실제 출발: 08:12:10

사용자가 08:08:20에 승강장에 도착했으므로 첫 번째 열차를 탈 수 있다.

6.3 환승역까지 지연 전파

현재 열차가 이미 96초 지연된 상태이므로 다음 역의 지연을 처음부터 다시 뺏으면 안 된다.

LightGBM은 다음 구간에서 지연이 얼마나 증가하거나 회복될지를 예측한다.

현재 지연: +96초
추가 지연 변화 표본: +12초
환승역 도착 지연: +108초

환승역 실제 도착: 08:29:48

6.4 환승 가능 여부

환승역 도착: 08:29:48
환승 보행시간 표본: 3분 20초
환승 준비 완료: 08:33:08

환승열차 실제 출발: 08:32:50

환승열차가 18초 먼저 출발했으므로 계획한 환승에는 실패한다.

6.5 다음 열차 선택

환승에 실패했다고 전체 여행을 실패 처리하지 않는다.

다음 열차 출발: 08:36:40
강남역 도착: 08:51:20

이 시뮬레이션의 최종 결과는 다음과 같다.

계획한 환승: 실패
목적지 도착: 성공
최종 도착시각: 08:51:20

7. Monte Carlo 반복 실행

위 과정을 약 2,500~10,000번 반복한다.

```
for simulation in range(10000):  
    집에서_승강장까지_이동()
```

```
첫_열차_지연 = LightGBM_분포에서_표본추출()
탑승_가능한_첫_열차_선택()
```

```
환승역까지_지연_전파()
환승시간_표본추출()
```

```
if 계획한_환승열차_탑승_가능:
    계획한_열차_탑승()
else:
    다음_열차_탑승()
```

```
목적지_도착시각_저장()
```

10,000번 실행한 결과가 다음과 같다고 가정한다.

결과	횟수
계획한 첫 열차와 환승열차로 09:00 전 도착	7,200
환승을 놓쳤지만 다음 열차로 09:00 전 도착	1,100
첫 열차를 놓쳤지만 대체 열차로 09:00 전 도착	300
09:00 이후 도착	1,400

최종 정시 도착확률은 다음과 같다.

```
(7,200 + 1,100 + 300) ÷ 10,000
= 86%
```

계획한 열차를 모두 그대로 탈 확률은 72%지만, 다음 열차까지 고려한 최종 정시 도착확률은 86%다.

8. 열차 지연의 연속성 처리

각 역의 지연을 독립적으로 표본추출하면 안 된다.

잘못된 방식

```
A역 지연: +120초
B역 지연: +10초
```

C역 지연: +180초

같은 열차인데 역마다 지연이 무관하게 변하는 문제가 발생한다.

권장 방식

현재 지연에서 다음 구간의 변화량만 예측한다.

A역 현재 지연:	+120초
A→B 지연 변화:	-15초
B역 지연:	+105초
B→C 지연 변화:	+25초
C역 지연:	+130초

또는 과거 열차 한 대의 전체 운행 궤적을 통째로 표본추출한다.

```
train_run_id
= 운행일 + 호선 + 방향 + 열차번호 + 종착역
```

각 열차의 역별 지연 흐름을 하나의 표본으로 보관하면 동일 열차의 지연 연속성과 같은 노선에서 발생하는 공통 지연을 보존할 수 있다.

9. 이동 중 새로 발생하는 지연

지연은 두 종류로 나눠 처리한다.

일상적인 지연

- 승하차 시간 증가
- 배차간격 변화
- 혼잡역 정차시간 증가
- 앞 열차와의 간격 조정

과거 운행 궤적과 LightGBM 학습 데이터에 포함하여 처리한다.

이례상황

- 열차 고장

- 안전사고
- 시위 및 역사 혼잡
- 무정차 통과
- 임시 시간표 변경

현재 발생 중인 사건은 서울교통공사 지하철 알림정보 API를 이용한다.


MVP에서는 현재 발생 중인 사건만 AI 입력값에 반영한다. 이동 중 새 사고가 발생할 확률을 예측하려면 알림과 사고 당시 지연 궤적을 수개월 이상 직접 축적해야 한다.

10. 필요한 데이터

계산 대상	데이터	사용 목적
경로 후보	<u>최단경로이동정보 API</u>	최소시간·최소환승 경로 생성
열차 시간표	<u>서울 도시철도 운행시각표</u>	다음 열차·막차 탐색
실시간 ETA	<u>지하철 실시간 도착정보</u>	현재 도착예정시각 계산
전체 열차 추적	<u>전체역 실시간 도착정보</u>	열차별 예측·도착·출발 이력 축적
열차 위치	<u>실시간 열차 위치정보</u>	현재역·방향·급행 검증
환승시간	<u>서울 도시철도 환승정보</u>	환승 위치와 기준시간
환승거리	<u>환승역 거리·소요시간</u>	환승 보행시간 초기값
이례상황	<u>지하철 알림정보</u>	현재 사고·지연 반영

공개 API는 열차별 과거 실시간 운행 궤적을 제공하지 않으므로 프로젝트에서 직접 수집해야 한다.

11. 시스템 구성



Spark 데이터 전처리·집계
↓
LightGBM Quantile 모델 학습
↓
지연 분위수 예측 API
↓
Monte Carlo Journey Engine
↓
정시 도착확률·환승 성공확률 제공

Flink와 Spark는 대용량 데이터를 수집·가공하는 역할을 하고, LightGBM은 지연분포를 예측한다. Monte Carlo는 예측된 분포를 전체 경로 결과로 변환한다.

12. 사용자에게 제공할 결과

예상 도착시각 P50: 08:52
보수적 도착시각 P90: 09:03

09:00 전 도착확률: 86%
계획한 환승 성공확률: 72%
환승 실패 후 복구확률: 61%

90% 확률로 도착하려면
08:07 이전 출발 권장

다음 두 확률은 반드시 분리해서 보여준다.

- 계획한 열차와 환승을 그대로 지킬 확률
- 대체 열차까지 포함해 목표 시각 전에 도착할 확률

13. MVP 권장 범위

전체 기능을 4주 안에 구현하려면 다음과 같이 제한한다.

- 서울 1~9호선 중 서울시 제공 구간
- 환승 최대 1회
- 목적지 기준은 하차 승강장
- 경로 생성은 서울교통공사 API에 위임
- 집 → 승강장 시간은 사용자가 입력
- 환승 실패 시 동일 노선의 다음 열차만 선택

- 현재 발생 중인 사고·지연만 반영
- t-digest를 기준 모델로 유지
- LightGBM으로 P10·P50·P90 이상의 분위수 예측
- 온라인 시뮬레이션 약 2,500회
- 발표 및 정밀 분석 약 10,000회

현재 기획서에서는 경로 탐색과 환승 안내가 MVP 제외 항목이다. 따라서 이 기능을 포함하면 기존 **역별 ETA 신뢰도 서비스**에서 **AI 기반 확률적 여정 플래너**로 프로젝트 범위가 확장된다.

14. 최종 정리

전체 계산 과정은 다음과 같다.

1. 경로 API가 이동 경로와 후보 열차를 찾는다.
2. LightGBM이 현재 상황에 맞는 열차 지연 확률분포를 예측한다.
3. Monte Carlo가 예측 분포에서 지연시간을 무작위로 표본추출한다.
4. 표본추출한 지연시간으로 첫 열차 탑승과 환승 가능 여부를 계산한다.
5. 열차를 놓치면 다음 열차를 선택한다.
6. 이 과정을 수천 번 반복한다.
7. 목표 시각 전에 도착한 비율을 최종 정시 도착확률로 제공한다.

핵심은 LightGBM이 최종 도착시간 하나를 예측하는 것이 아니다.

LightGBM이 열차 지연의 확률분포를 예측하고, Monte Carlo가 그 분포를 이용해 가능한 여행 상황을 반복 실행하여 전체 경로의 도착확률을 계산한다.